

Documentation Technique - Monitoring et Gestion des Incidents

Projet IMAGE_ORGANISATION

1. Architecture du dispositif de monitoring

1.1 Composants du système

Composant	Rôle	Technologie
Module de prédiction	Chargement du modèle ResNet50, prétraitement des images, inférence	TensorFlow / Keras
Fichier de configuration centralisé	Centralisation de tous les paramètres (modèle, seuils, RGPD)	Python dict
Système de journalisation	Enregistrement horodaté de chaque événement applicatif	<code>logging</code> Python
Historique des prédictions	Persistance des résultats, des scores de confiance et des retours utilisateurs	CSV (pandas)
Interface de monitoring	Tableau de bord temps réel des métriques clés	Gradio
API REST	Exposition des endpoints de prédiction, santé et métriques	FastAPI

1.2 Flux de données

À chaque requête, l'image est prétraitée, soumise au modèle, puis le résultat est journalisé, persisté dans l'historique et vérifié contre les seuils d'alerte configurés.

2. Conformité RGPD du monitoring

2.1 Données collectées et politique de rétention

Donnée	Collectée
Classe prédite (label)	Oui
Score de confiance (%)	Oui
Temps de réponse (ms)	Oui
Horodatage de la requête	Oui
Top 5 des classes candidates	Oui

Donnée	Collectée
Feedback Correcte / Incorrecte	Oui
Visages, identités, données sensibles	Non
Nom, email, adresse IP de l'utilisateur	Non
Fichier image source	Non

L'historique est limité à 1 000 entrées et 90 jours (purge automatique). Un bouton dédié dans l'interface permet l'effacement immédiat à la demande. Aucune donnée n'est transmise vers un tiers ou un service cloud — stockage local uniquement, base légale : intérêt légitime (amélioration d'un système IA).

3. Métriques surveillées et seuils d'alerte

Métrique	Description	Unité	Seuil d'alerte	Niveau de sévérité	Action déclenchée
Score de confiance	Niveau de certitude du modèle sur la prédiction principale	%	< 30 %	WARNING	Journalisation de l'événement - signalement confiance faible
Erreurs consécutives	Nombre d'échecs de prédiction successifs sans succès intercalé	Nombre	≥ 3	CRITICAL	Alerte critique - intervention humaine requise
Taux d'erreur global	Ratio erreurs / prédictions totales	%	Indicatif	INFO	Affiché dans le tableau de bord - aucune action automatique
Temps de réponse moyen	Latence moyenne de traitement par requête	ms	Indicatif	INFO	Affiché dans le tableau de bord
Précision feedback	Ratio prédictions correctes / feedbacks soumis	%	Indicatif	INFO	Alimentation de la boucle d'amélioration continue
Volume historique	Nombre total d'entrées dans l'historique	Lignes	1 000	INFO	Troncature automatique - conformité RGPD

4. Mécanismes de détection automatique

4.1 Détection des anomalies de qualité de prédiction

À chaque inférence réussie, le score de confiance de la classe principale est comparé au seuil configuré (30 %). Si ce seuil n'est pas atteint, un événement de niveau WARNING est automatiquement émis dans le fichier de

logs, identifiant la classe prédite et le score obtenu. Ce mécanisme permet de détecter les images ambiguës, dégradées ou hors distribution d'entraînement sans interrompre le service.

4.2 Détection des incidents de stabilité

Un compteur d'erreurs consécutives est maintenu en mémoire pendant l'exécution. À chaque exception levée lors d'une prédiction, ce compteur est incrémenté et un événement ERROR est journalisé. Dès que le compteur atteint ou dépasse le seuil de 3, un événement de niveau CRITICAL est émis, signalant qu'une intervention humaine est nécessaire. Le compteur est remis à zéro dès qu'une prédiction aboutit avec succès.

4.3 Détection des dégradations de performance

À chaque prédiction, le temps de réponse mesuré est comparé au seuil de latence configuré (1 000 ms). Tout dépassement de ce seuil génère automatiquement un événement de niveau WARNING dans le fichier de logs, indiquant la valeur mesurée et le seuil de référence. Ce mécanisme permet de détecter une dégradation des performances avant qu'elle n'impacte l'expérience utilisateur. Le seuil est paramétrable dans le fichier de configuration centralisé.

5. Fiche incident INC-001

5.1 Tableau synthétique

Champ	Valeur
Identifiant	INC-001
Date de détection	28 avril 2025 - 10h14
Date de résolution	28 avril 2025 - 10h52
Durée totale	38 minutes
Gravité	Critique
Module impacté	Fonction de prétraitement des images - module de prédiction
Cause racine	Valeur de redimensionnement codée en dur incorrecte : (64, 64) au lieu de (224, 224)
Mode de détection	Automatique - journalisation + alerte CRITICAL après 3 erreurs consécutives
Périmètre d'impact	100 % des requêtes - aucune prédiction possible
Statut	Résolu

5.2 Symptôme - traces de journalisation

Toutes les requêtes envoyées à l'endpoint de prédiction retournaient une erreur HTTP 500. Le fichier de logs enregistrait automatiquement la séquence suivante :

```
2025-04-28 10:15:03 - ERROR - Erreur lors de la prédiction :  
  Input 0 of layer "resnet50" is incompatible with the layer:  
    expected shape=(None, 224, 224, 3), found shape=(None, 64, 64, 3)  
[x3 occurrences]  
2025-04-28 10:15:04 - CRITICAL - INCIDENT CRITIQUE - 3 erreurs consécutives !  
Intervention requise.
```

Le message d'erreur identifie précisément l'incompatibilité : le tenseur fourni au modèle présentait la forme `(None, 64, 64, 3)` alors que ResNet50 impose strictement `(None, 224, 224, 3)`.

5.3 Diagnostic - cause racine

Cause racine identifiée : la valeur `(64, 64)` avait été introduite en phase de développement pour accélérer les tests avec des images de petite taille. Elle n'avait pas été corrigée avant la mise en service, et aucun garde-fou (assertion, validation d'entrée) n'existait pour détecter cette incohérence à l'initialisation.

5.4 Correction - comparaison avant / après

Avant correction - valeur codée en dur, découplée du paramétrage central :

```
img = img.resize((64, 64))
```

Après correction - lecture depuis le fichier de configuration centralisé :

```
img = img.resize(MODEL_CONFIG["input_shape"]) # → (224, 224)
```

5.5 Validation de la correction

Test réalisé	Attendu	Obtenu	Résultat
Prédiction image (labrador.jpg)	Classe identifiée, confiance > 30 %	"Labrador Retriever" - 87,43 % - 312 ms	Succès
Absence d'erreur dans les logs	Aucun événement ERROR ou CRITICAL	INFO - Prédiction OK : 'Labrador Retriever'	Confiance : 87.43%
Endpoint métriques GET /metrics	Métriques cohérentes post-correction	predictions_totales: 1, erreurs: 0, confiance_moyenne_pct: 87.43	Succès

5.6 Comparatif - impact du monitoring sur la résolution

Dimension	Sans monitoring	Avec monitoring
Détection de l'incident	Signalement manuel par un utilisateur - délai indéterminé	Automatique - alerte CRITICAL après 3 erreurs consécutives (< 5 secondes)
Identification de la cause	Lecture du code source de bout en bout - investigation non guidée	Message d'erreur précis dans les logs : incompatibilité de forme (64,64) vs (224,224)
Délai total de résolution	Non estimable	38 minutes - détection à correction incluse

6. Mesures préventives et capitalisation

À la suite de l'incident INC-001, quatre mesures structurantes ont été mises en place pour réduire la probabilité et l'impact de tout incident similaire :

Mesure 1 - Centralisation des paramètres : plus aucune valeur technique codée en dur — toute modification s'effectue dans le fichier de configuration centralisé.

Mesure 2 - Seuil d'alerte à 3 erreurs consécutives : détection automatique d'incident dès trois échecs successifs, seuil paramétrable.

Mesure 3 - Documentation standardisée des incidents : chaque incident fait l'objet d'une fiche structurée (chronologie, diagnostic, correction, validation).

Mesure 4 - Endpoint de santé avec contrôles réels : vérification du modèle en mémoire, de l'historique et du système de journalisation avant la première prédiction.

7. Bilan

Le dispositif de monitoring couvre trois axes de surveillance : la qualité des prédictions (seuil de confiance < 30 %), la stabilité du service (alerte CRITICAL après 3 erreurs consécutives) et les performances (latence > 1 000 ms). L'ensemble fonctionne sans infrastructure externe, avec un coût de maintenance quasi nul.

L'incident INC-001 a validé l'efficacité du dispositif : détection automatique en moins de 5 secondes, diagnostic immédiat via les logs, résolution complète en 38 minutes.

Les mesures préventives adoptées (centralisation des paramètres, alertes automatiques, endpoint de santé, documentation systématique) réduisent le risque de récurrence et accélèrent la résolution de tout incident futur.

Les données collectées alimentent une boucle d'amélioration continue : les prédictions à faible confiance et les feedbacks négatifs identifient les faiblesses du modèle en production, orientant les décisions d'ajustement des seuils, d'enrichissement des données d'entraînement ou de remplacement du modèle. Ce cycle (prédiction → feedback → analyse → amélioration → redéploiement) est opérationnel dès le premier lancement.