

Documentation Technique - Monitoring et Gestion des Incidents

Projet IMAGE_ORGANISATION


1. Architecture du dispositif de monitoring

1.1 Composants du système

Composant	Rôle	Technologie
Module de prédiction	Chargement du modèle ResNet50, prétraitement des images, inférence	TensorFlow / Keras
Fichier de configuration centralisé	Centralisation de tous les paramètres (modèle, seuils, RGPD)	Python dict
Système de journalisation	Enregistrement horodaté de chaque événement applicatif	logging Python
Historique des prédictions	Persistance des résultats, des scores de confiance et des retours utilisateurs	CSV (pandas)
Interface de monitoring	Tableau de bord temps réel des métriques clés	Gradio
API REST	Exposition des endpoints de prédiction, santé et métriques	FastAPI

1.2 Flux de données - schéma ASCII





2. Conformité RGPD du monitoring

2.1 Données collectées vs données exclues

Catégorie	Donnée	Collectée	Justification
Résultat d'inférence	Classe prédite (label)	Oui	Nécessaire au suivi qualité du modèle
Résultat d'inférence	Score de confiance (%)	Oui	Nécessaire à la détection d'anomalies
Performance	Temps de réponse (ms)	Oui	Nécessaire au monitoring de performance
Temporalité	Horodatage de la requête	Oui	Nécessaire à la traçabilité des incidents
Qualité	Top 5 des classes candidates	Oui	Nécessaire à l'analyse post-incident
Retour utilisateur	Feedback Correcte / Incorrecte	Oui	Alimentation volontaire de la boucle qualité
Données biométriques	Visages, identités, données sensibles	Non	Hors périmètre - aucune collecte

Catégorie	Donnée	Collectée	Justification
Données personnelles	Nom, email, adresse IP de l'utilisateur	Non	Non requises par le service
Contenu image	Fichier image source	Non	Aucun stockage - traitement en mémoire uniquement

2.2 Politique de rétention

Paramètre	Valeur configurée	Mécanisme appliqué
Volume maximal conservé	1 000 entrées	Suppression automatique des entrées les plus anciennes au dépassement
Durée maximale de conservation	90 jours	Purge automatique des entrées au-delà de 90 jours
Effacement à la demande	Disponible	Bouton dédié dans l'interface - réinitialisation immédiate de l'historique
Périmètre de stockage	Local uniquement	Aucune transmission vers un tiers ou un service cloud
Base légale du traitement	Intérêt légitime - amélioration d'un système IA	Limitation stricte à la finalité de monitoring

3. Métriques surveillées et seuils d'alerte

Métrique	Description	Unité	Seuil d'alerte	Niveau de sévérité	Action déclenchée
Score de confiance	Niveau de certitude du modèle sur la prédiction principale	%	< 30 %	WARNING	Journalisation de l'événement - signalement confiance faible
Erreurs consécutives	Nombre d'échecs de prédiction successifs sans succès intercalé	Nombre	≥ 3	CRITICAL	Alerte critique - intervention humaine requise
Taux d'erreur global	Ratio erreurs / prédictions totales	%	Indicatif	INFO	Affiché dans le tableau de bord - aucune action automatique
Temps de réponse moyen	Latence moyenne de traitement par requête	ms	Indicatif	INFO	Affiché dans le tableau de bord

Métrique	Description	Unité	Seuil d'alerte	Niveau de sévérité	Action déclenchée
Précision feedback	Ratio prédictions correctes / feedbacks soumis	%	Indicatif	INFO	Alimentation de la boucle d'amélioration continue
Volume historique	Nombre total d'entrées dans l'historique	Lignes	1 000	INFO	Troncature automatique - conformité RGPD

4. Mécanismes de détection automatique

4.1 Détection des anomalies de qualité de prédiction

À chaque inférence réussie, le score de confiance de la classe principale est comparé au seuil configuré (30 %). Si ce seuil n'est pas atteint, un événement de niveau WARNING est automatiquement émis dans le fichier de logs, identifiant la classe prédite et le score obtenu. Ce mécanisme permet de détecter les images ambiguës, dégradées ou hors distribution d'entraînement sans interrompre le service.

```

Confiance obtenue < 30 %
    |
    ▼
WARNING - "Confiance faible : XX.XX% pour 'classe' (seuil : 30%)"
    |
    ▼
Prédiction sauvegardée dans l'historique (marquée comme suspecte par le score)
  
```

4.2 Détection des incidents de stabilité

Un compteur d'erreurs consécutives est maintenu en mémoire pendant l'exécution. À chaque exception levée lors d'une prédiction, ce compteur est incrémenté et un événement ERROR est journalisé. Dès que le compteur atteint ou dépasse le seuil de 3, un événement de niveau CRITICAL est émis, signalant qu'une intervention humaine est nécessaire. Le compteur est remis à zéro dès qu'une prédiction aboutit avec succès.

```

Exception lors de l'inférence
    |
    ▼
ERROR - message d'erreur technique
compteur_erreurs += 1
    |
    ▼
compteur ≥ 3 ?
  /   \
Non   Oui
 |     |
(fin) ▼
  
```

CRITICAL - "INCIDENT CRITIQUE - N erreurs consécutives ! Intervention requise."

4.3 Détection des dégradations de performance

À chaque prédiction, le temps de réponse mesuré est comparé au seuil de latence configuré (1 000 ms). Tout dépassement de ce seuil génère automatiquement un événement de niveau WARNING dans le fichier de logs, indiquant la valeur mesurée et le seuil de référence. Ce mécanisme permet de détecter une dégradation des performances avant qu'elle n'impacte l'expérience utilisateur. Le seuil est paramétrable dans le fichier de configuration centralisé.

```
Temps de réponse mesuré > 1 000 ms
  |
  ▼
WARNING - "Latence anormale : XXXXms (seuil : 1000ms)"
  |
  ▼
Événement journalisé - métriques de latence mises à jour dans l'historique
```

5. Fiche incident INC-001

5.1 Tableau synthétique

Champ	Valeur
Identifiant	INC-001
Date de détection	28 avril 2025 - 10h14
Date de résolution	28 avril 2025 - 10h52
Durée totale	38 minutes
Gravité	Critique
Module impacté	Fonction de prétraitement des images - module de prédiction
Cause racine	Valeur de redimensionnement codée en dur incorrecte : (64, 64) au lieu de (224, 224)
Mode de détection	Automatique - journalisation + alerte CRITICAL après 3 erreurs consécutives
Périmètre d'impact	100 % des requêtes - aucune prédiction possible
Statut	Résolu

5.2 Symptôme - traces de journalisation

Toutes les requêtes envoyées à l'endpoint de prédiction retournaient une erreur HTTP 500. Le fichier de logs enregistrait automatiquement la séquence suivante :

```
2025-04-28 10:14:32 - INFO - Initialisation du système de classification
d'images...
2025-04-28 10:14:45 - INFO - Modèle ResNet50 chargé avec succès.
2025-04-28 10:14:51 - INFO - Fichier historique créé.
2025-04-28 10:15:03 - ERROR - Erreur lors de la prédiction :
    Input 0 of layer "resnet50" is incompatible with the layer:
    expected shape=(None, 224, 224, 3), found shape=(None, 64, 64, 3)
2025-04-28 10:15:03 - ERROR - Erreur lors de la prédiction :
    Input 0 of layer "resnet50" is incompatible with the layer:
    expected shape=(None, 224, 224, 3), found shape=(None, 64, 64, 3)
2025-04-28 10:15:03 - ERROR - Erreur lors de la prédiction :
    Input 0 of layer "resnet50" is incompatible with the layer:
    expected shape=(None, 224, 224, 3), found shape=(None, 64, 64, 3)
2025-04-28 10:15:04 - CRITICAL - INCIDENT CRITIQUE - 3 erreurs consécutives !
Intervention requise.
```

Le message d'erreur identifie précisément l'incompatibilité : le tenseur fourni au modèle présentait la forme `(None, 64, 64, 3)` alors que ResNet50 impose strictement `(None, 224, 224, 3)`.

5.3 Diagnostic - chaîne de traitement

L'analyse de la chaîne de traitement a permis d'isoler le point de défaillance dans la fonction de prétraitement des images :

```
Image reçue (format quelconque, dimensions quelconques)
    |
    ▼
preprocess_image()
  └─ img.resize((64, 64))  ← POINT DE DÉFAILLANCE
    |
    ▼
np.expand_dims() → tenseur shape (1, 64, 64, 3)
    |
    ▼
ResNet50.predict()
  └─ attend shape (1, 224, 224, 3)
    |
    ▼
EXCEPTION - incompatibilité de dimensions
    |
    ▼
ERROR log → CRITICAL log (après 3 occurrences)
```

Cause racine identifiée : la valeur `(64, 64)` avait été introduite en phase de développement pour accélérer les tests avec des images de petite taille. Elle n'avait pas été corrigée avant la mise en service, et aucun garde-

fou (assertion, validation d'entrée) n'existait pour détecter cette incohérence à l'initialisation.

5.4 Correction - comparaison avant / après

Avant correction - valeur codée en dur, découplée du paramétrage central :

```
# Valeur incorrecte - ne correspond pas aux contraintes de ResNet50
img = img.resize((64, 64))
```

Après correction - lecture depuis le fichier de configuration centralisé :

```
# Valeur lue depuis la configuration centralisée - garantit la cohérence
img = img.resize(MODEL_CONFIG["input_shape"]) # → (224, 224)
```

Extrait correspondant du fichier de configuration centralisé :

```
MODEL_CONFIG = {
    "model_name": "ResNet50",
    "weights": "imagenet",
    "input_shape": (224, 224), # contrainte stricte de ResNet50
    "top_k": 5
}
```

5.5 Validation de la correction

Test réalisé	Attendu	Obtenu	Résultat
Endpoint de santé GET /health	{"statut": "ok", "modele": "ResNet50"}	{"statut": "ok", "modele": "ResNet50"}	Succès
Prédiction image (labrador.jpg)	Classe identifiée, confiance > 30 %	"Labrador Retriever" - 87,43 % - 312 ms	Succès
Absence d'erreur dans les logs	Aucun événement ERROR ou CRITICAL	`INFO - Prédiction OK : 'Labrador Retriever'	Confiance : 87.43%
Remise à zéro du compteur d'erreurs	<code>consecutive_errors = 0</code>	Confirmé par endpoint métriques - "erreurs": 0	Succès
Endpoint métriques GET /metrics	Métriques cohérentes post- correction	<code>predictions_totales: 1,</code> <code>erreurs: 0,</code> <code>confiance_moyenne_pct: 87.43</code>	Succès

5.6 Comparatif - impact du monitoring sur la résolution

Dimension	Sans monitoring	Avec monitoring
Détection de l'incident	Signalement manuel par un utilisateur - délai indéterminé	Automatique - alerte CRITICAL après 3 erreurs consécutives (< 5 secondes)
Identification de la cause	Lecture du code source de bout en bout - investigation non guidée	Message d'erreur précis dans les logs : incompatibilité de forme (64,64) vs (224,224)
Délai de diagnostic	Estimé à plusieurs heures	Inférieur à 10 minutes - message d'erreur auto-documenté
Traçabilité	Aucune - perte de l'historique des échecs	Complète - horodatage, fréquence, nature de chaque erreur archivés
Délai total de résolution	Non estimable	38 minutes - détection à correction incluse

6. Mesures préventives et capitalisation

À la suite de l'incident INC-001, trois mesures structurantes ont été mises en place pour réduire la probabilité et l'impact de tout incident similaire :

Mesure 1 - Centralisation de l'ensemble des paramètres techniques dans le fichier de configuration

Aucune valeur numérique technique (taille d'image, seuil de confiance, limite de rétention) n'est désormais codée en dur dans le code applicatif. Toute modification de paramètre s'effectue en un point unique, éliminant les risques d'incohérence entre les différents modules de l'application - qu'il s'agisse du module de prédiction, de l'interface ou de l'API REST.

Mesure 2 - Seuil d'alerte sur les erreurs consécutives configuré à 3 occurrences

Le mécanisme de détection automatique d'incident est activé dès trois échecs successifs. Ce seuil, paramétrable dans le fichier de configuration centralisé, garantit qu'aucun dysfonctionnement systémique ne peut passer inaperçu plus de quelques secondes. Toute modification de seuil est traçable via le contrôle de version.

Mesure 3 - Documentation systématique de chaque incident selon un modèle standardisé


Chaque incident technique fait l'objet d'une fiche structurée couvrant : la chronologie, les traces de journalisation, le diagnostic de cause racine, la correction appliquée avec comparaison avant/après, et la validation. Cette capitalisation constitue une base de connaissance opérationnelle permettant de réduire le temps de résolution des incidents futurs.

Mesure 4 - Endpoint de vérification préalable avec contrôles réels

L'endpoint de santé vérifie trois conditions avant toute utilisation du service : le modèle est chargé en mémoire, le fichier d'historique est accessible en lecture/écriture, et le système de journalisation est disponible en écriture. Ce mécanisme permet de détecter une défaillance structurelle avant même la première prédiction, sans attendre qu'un utilisateur rencontre une erreur.

7. Boucle d'amélioration continue - feedback loop

7.1 Cycle d'amélioration - schéma ASCII



7.2 Signaux de la boucle et décisions associées

Signal	Source	Indicateur calculé	Décision possible
Feedback "Incorrecte" fréquent sur une catégorie	Retours utilisateurs	Taux d'erreur par classe (analyse manuelle du CSV)	Réévaluation du seuil de confiance - investigation des cas limites
Confiance moyenne en baisse	Métriques temps réel	<code>confiance_moyenne_pct</code> < valeur de référence	Vérification de la distribution des images soumises - suspicion de dérive
Augmentation du taux d'erreurs techniques	Logs d'erreur	<code>erreurs /</code> <code>predictions_totales</code> en hausse	Diagnostic infrastructure - analyse des exceptions journalisées
Score de confiance faible récurrent	Détection automatique WARNING	Nombre d'entrées sous le seuil de 30 %	Ajustement du seuil ou enrichissement des données d'entraînement
Alerte CRITICAL déclenchée	Détection automatique	Compteur erreurs consécutives ≥ 3	Intervention humaine immédiate - diagnostic via les logs - correction du code
Volume historique proche de la limite RGPD	Contrôle de rétention	Nombre de lignes ≥ 1 000	Troncature automatique - archivage optionnel avant suppression

Version 1.0 - Mai 2026 - Gabriel Guery - Projet IMAGE_ORGANISATION